

Reporte de Series de Tiempo (Salud pública, Financiero y Desempeño Educativo)

Autores:

Hurtado Ramos Arianna Monserratt

Rivera Anguiano Barbara Daria

Índice

Salud pública	4
Life Expectancy Dataset Kaggle	4
Air Pollution and Health Dataset Kaggle	4
Adolescent fertility Dataset Kaggle	6
Financiero	7
S&P 500 Historical Prices	7
Bitcoin Historical Data	10
VIX – Volatility Index	12
Desempeño educativo	14
World Bank Education Statistics Kaggle	14
Times World University Rankings Dataset Kaggle	15
UNESCO – Tasa de Finalización (Secundaria básica, ambos sexos)	16
Conclusión	17

Introducción

En el estudio de modelos predictivos de Machine Learning en especial si trabajamos con series temporales, podemos denotar que hay diversidad de modelos con su respectiva arquitectura y usos frecuentes que puedan ser más convenientes usar en ciertos ámbitos de estudio, o si trabajamos con datos que presenten factores ya sea de linealidad, estacionalidad o que sean en gran volumen o menor . Por ello en este estudio pretendemos hacer uso de distintos datasets públicos que conllevan datos desde el área de salud, financieras y educativas, por lo cual los datos son bastante diferentes entre sí, ya sea que estén en grandes volúmenes, pocos, o que existan ciertas fluctuaciones para posteriormente aplicar diversos modelos de predicción como ARIMA, Prophet, Media Móvil, LSTM, TRANSFORMER y un modelo IAG para finalizar evaluando su desempeño predictivo en base a las métricas de SMAPPE, MAPE, MAE, RMSE, e incluyendo una Análisis de Explicabilidad XAI . El propósito de estudio será hacer una comparativa entre Modelos Estadísticos, de Deep Learning e IA y ver cuál da mejores resultados, o si depende de ciertos factores, e incluso ver la probabilidad de usar modelos híbridos.

Salud pública

Life Expectancy Dataset Kaggle

El presente análisis del dataset Life Expectancy en donde se pretende predecir la esperanza de vida en México hasta el 2026 aplicando modelos como ARIMA, Prophet, Media Móvil, LSTM, TRANSFORMER y un modelo IAG. Prophet nos arrojó un MAPE de 0% al igual que SMAPE por lo que no hay diferencia alguna lo que indica un desempeño perfecto, en cambio en Arima nos dio un 0.14% en ambas métricas dando un rendimiento excelente, lo mismo con LSTM con un 0.18% con rendimiento intermedio y Transformer con un 0.21% con un pésimo rendimiento mostrando que la memoria adicional no está mostrando ventaja a pesar de su mecanismo de atención. Si Prophet presenta un rendimiento perfecto no muestra una naturalidad del todo en condiciones normales por lo que tiene un overfitting o que simplemente memorizar datos, por lo que tomaremos con el mejor rendimiento a ARIMA dado sus características rígidas y lineales que refleja un buen comportamiento a sus datos lineales, indicando que se ajustó mejor a la cantidad de datos.

El modelo con menor error fue Prophet y de mayor fue Transformer dado que había muy pocos datos y este necesita de más para que la puerta de memoria pueda clasificar entre qué información mantener y cuál olvidar por lo cual es hipersensible.

Con base a XAI podemos ver que ARIMA y Prophet son los más transparentes dado que nos muestran la tendencia y la estacionalidad y un error residual en cambio LSTM y Transformer son los más inciertos porque no se sabe que neurona nos dio la precisión exacta. En cambio ARIMA mostró fuertemente lags de influencia hacia el pasado, y Prophet solo nos da los aditivos, es decir solo nos dice que valor se debe a que día. Transformer utiliza la atención que le da más peso a ciertos valores del pasado, y LSTM hace uso de las celdas de la memoria por lo que nos da la información más relevante.

Finalmente para abrir las cajas negras en Transformer se usó los mapas de atención, para LSTM e IA se usó XAI, sin embargo a todos se les dio una importancia temporal y ARIMA nos dejó ver un claro patrón de migajas dejando algunos residuos. En conclusión el mejor modelo y el más adecuado sería Prophet ajustando los datos correctamente y proporcionando un equilibrio entre precisión y estabilidad, además de proporcionar una explicabilidad de sus proyecciones, dando en un desempeño superior con los demás modelos dado su valores negativos en r^2 .

Air Pollution and Health Dataset Kaggle

El dataset de Air Quality in India que predice la cantidad de partículas de PM2.5 aplicando modelos como ARIMA, Prophet, Media Móvil, LSTM, TRANSFORMER y un modelo IAG. Prophet nos dio el desempeño más bajo con un MAPE de 22.98% y en SMAPE un 19.39% por

lo que tuvo cambios muy bruscos en la estacionalidad, en cambio en Arima nos dio un rendimiento intermedio con un 18.58% en MAPE y en SMAPE 16.21% , con LSTM con un MAPE de 14.31% y con SMAPE de 12.64% con rendimiento superior al resto y Transformer con un MAPE de 17.34% y con un SMAPE del 19.94% con un rendimiento interior mostrando cierta sensibilidad y Media Movil siendo de los modelos más precisos con un MAPE de 10.27% y un 14.94% de SMAPE filtrando ciertos cambios.

El modelo con menor error fue Media móvil y de mayor fue Prophet. Con base a XAI podemos ver que ARIMA y Prophet son los más transparentes dado que nos muestran la tendencia lineales en cambio LSTM y Transformer son los que más presentan “Caja Negra” porque no se sabe el punto exacto de la decisión nos dio la precisión exacta y en cuanto a Gemini podemos ver que dio resultados más coherentes y justificados. En cambio ARIMA mostró fuertemente lags de influencia hacia el pasado, y Prophet solo nos da los aditivos, es decir solo nos dice que valor se debe a que día. Transformer utiliza la atención que le da más peso a ciertos valores del pasado , y LSTM hace uso de las celdas de la memoria por lo que nos da la información más relevante.

En conclusión el mejor modelo y el más adecuado sería LSTM dando el error más bajo que otros modelos, además de justificarse mejor con XAI en la que se basa en cuestión de la presión atmosférica y revelando el efecto post-pandemia, además de dar una mejor proyección hacia el 2026.

Adolescent fertility Dataset Kaggle

Este dataset presenta las tasas de fertilidad de adolescentes entre 15-19 años a nivel mundial, además de predecir su cifra para el 2026 con diversos modelos aplicados. Prophet nos dio el desempeño más bajo con un MAPE de 1.94% y en SMAPE un 1.96% mostrando uno de los rendimientos más sólidos capturando la tendencia a largo plazo dado que la tasa de fertilidad es un ciclo social por lo que no tuvo problema en adaptarse, en cambio en Arima nos dio un rendimiento intermedio con un 0.21% en MAPE y en SMAPE con un R^2 elevado mostrando una fuerte memoria a corto plazo además su éxito radica en que la tasa de un año es el resultado de la tasa anterior, con LSTM con un MAPE de 0.52 % y con SMAPE igual además de capturar la persistencia de los cambios generacionales y Transformer con un MAPE de 40.23% y con un SMAPE del 33.49% con un mecanismo de atención mostrando los cambios ocurridos durante 15 años con un peso mayor hacia la predicción del 2026 y Media Movil siendo de los modelos más precisos con un MAPE de 0.27% y un de SMAPE igual el cual nos permitió ver la tendencia descendente a partir de los 60's.

El modelo con menor error fue Media móvil y de mayor fue Prophet. Con base a XAI podemos ver que ARIMA y Prophet son los más transparentes dado que nos muestran la tendencia lineales en cambio LSTM y Transformer son los que más presentan “Caja Negra” porque no se sabe el punto exacto de la decisión nos dio la precisión exacta. Incluso podemos ver que el 75% de la predicción depende de los últimos 3 años y que las instituciones de salud están fuertemente conectadas y en cuanto a Gemini podemos ver que dio resultados más conectados a la realidad social, demostrando que el éxito del 2026 radicó en la buena implementación de políticas de salud reproductiva. En cambio ARIMA fue el mejor modelo con una precisión técnica y estable con el MAE más bajo de 0.096 dado que sus cambios son graduales.

Financiero

S&P 500 Historical Prices

Al evaluar los resultados obtenidos en este estudio, existe una diferencia en la precisión de los cinco modelos utilizados para predecir el comportamiento del S&P 500. Al analizar las métricas de error, se observa que el modelo de Inteligencia Artificial Generativa (Gemini) logró el mejor desempeño con un margen de error bastante bajo, registrando un MAPE de 0.1995% y un sMAPE de 0.1993%. En cambio, el modelo Transformers fue el que presentó el peor rendimiento dentro de la comparativa, con un error porcentual simétrico (sMAPE) que llegó hasta el 22.3931%, lo que muestra una dificultad importante para ajustarse a la tendencia alcista de la serie analizada.


Entre estos dos extremos, los modelos estadísticos tradicionales mostraron resultados bastantes buenos. Prophet se colocó como el segundo modelo más preciso con un sMAPE de 0.9983%, seguido por ARIMA, que obtuvo un 2.6935%. Por otro lado, el modelo de red neuronal recurrente LSTM, a pesar de su capacidad que tiene para captar patrones secuenciales, quedó en la cuarta posición con un sMAPE de 8.3021%. Estos resultados permiten ver que para este conjunto de datos en particular, los modelos basados en razonamiento generativo y en descomposición estadística lograron superar a arquitecturas más complejas de aprendizaje profundo.

Las diferencias que se encuentran en el comportamiento de los modelos se explican en gran parte por su arquitectura y por la naturaleza volátil que tiene el índice bursátil. En el caso de ARIMA, al ser un modelo matemático enfocando en una memoria de corto plazo y que utiliza la diferenciación para estabilizar o suavizar la serie, esta logró captar la dirección general pero tendió a volverse una proyección más lineal, dejando un poco de lado la volatilidad diaria que se tiene. Por otra parte, Prophet destacó por su capacidad que tiene para descomponer la serie en tendencia y estacionalidad, lo que le permitió tener una visión más estructurada y resistente en cuanto a las fluctuaciones del mercado, enfocándose más en la tendencia estable a largo plazo que se tenía que en cada variación pequeña que existía.

Dentro de los modelos de Deep Learning, el LSTM mostró tener un mejor desempeño que el Transformer en esta serie de tiempo. El LSTM logra captar mejor el “momentum” del mercado tras procesar la información de una manera secuencial, reaccionando más rápido a los cambios que se tenían en la pendiente. En cambio, Transformer adoptó una postura más conservadora, en la cual subestimó de forma considerable la fuerza alcista que tenía S&P 500 y generando una curva con menos ruido, pero también más alejada de la realidad. Por lo tanto, esto sugiere que esta arquitectura necesita un ajuste de hiperparámetros más cuidadoso para este tipo de series temporales. El buen desempeño del modelo IAG (Gemini) se explica por la capacidad que tiene al realizar un “zero-shot forecasting” basado en el reconocimiento de patrones y en el razonamiento sobre los últimos 60 días de datos, la cual fue nuestra ventana, logrando un predicción final de 6,910.00 USD, muy cercana al valor real que se tiene de 6,896.24 USD.

La interpretabilidad de los modelos varían bastante dependiendo de su tipo. Los modelos clásicos como ARIMA y Prophet son más transparentes, ya que sus predicciones se basan en parámetros matemáticos y en componentes tendencia que un analista puede revisar directamente. En el otro extremo están el LSTM y el Transformer, que estos funcionan como “cajas negras” ya que la relación entre los datos de entrada y las predicciones finales no es tan fácil de entender sin el uso de herramientas adicionales. Aunque existen técnicas avanzadas para abordar esta falta de claridad, como lo son valores de SHAP, los mecanismos de atención de Transformer o el análisis de importancia temporal, aún no se implementó en este trabajo para las redes neuronales.

La explicabilidad (XIA) se aplicó de una forma directa únicamente al modelo IAG, mediante una análisis de coherencia y Explicabilidad integrado en la respuesta obtenida por Gemini. El modelo no solo generó el valor numérico que representa a la predicción de este modelo, sino que también justificó su predicción al identificar una tendencia alcista sólida y dar un peso mayor a la recencia de los datos, es decir, a los movimientos de los últimos tres días. Esto permitió entender que el modelo tomó su decisión con un nivel de confianza medio debido a la volatilidad histórica, convirtiéndolo así de una simple predicción en una herramienta con mayor contexto y sentido lógico.



EVALUACIÓN DE DESEMPEÑO Y COMPARATIVA DE MÉTRICAS DE ERROR (S&P 500)				
VALOR REAL DE REFERENCIA: \$6,896.24 USD				
Modelo	MAE (USD)	RMSE	MAPE (%)	sMAPE (%)
IAG Gemini	\$13.76	13.76	0.1995%	0.1993%
Prophet	\$68.50	68.50	0.9934%	0.9983%
ARIMA	\$183.28	183.28	2.6577%	2.6935%
LSTM	\$549.71	549.71	7.9712%	8.3021%
Transformer	\$1,388.78	1,388.78	20.1383%	22.3931%
Nota: El ranking está ordenado por sMAPE (precisión simétrica).				

Bitcoin Historical Data

Al finalizar la fase de experimentación en relación con los cinco modelos predictivos seleccionados se elaboró un ranking de desempeño que se basó en la precisión de sus pronósticos frente al valor real que tenía el Bitcoin, el cual estaba entre los 71,200.00 USD al cierre del periodo de prueba. Estos resultados evidenciaron una existente diferencia entre las tecnologías más recientes y los métodos tradicionales. El modelo IAG (Gemini) se posicionó como el mejor de todos, con un error porcentual absoluto medio (MAPE) y un error porcentual absoluto medio simétrico (sMAPE) de apenas 0.14%, logrando una predicción de 71,300.00 USD que se encuentra cerca del valor real. En segundo lugar se encuentra la red neuronal de memoria a largo plazo y corto plazo, el LSTM mostró un buen nivel de predicción con un sMAPE de 1.74%, lo cual implica una diferencia de 1,255.61 USD en relación al valor real. Por otro lado, los modelos con mayor margen de error fueron aquellos que están basados en enfoques estadísticos clásicos y arquitecturas menos flexibles ante el ruido local. El modelo Transformer presentó un sMAPE del 14.60% quedando atrás por casi 10,000 USD, este estimó un valor de 61,508.95 USD. Y por último, Prophet y ARIMA fueron los que tuvieron un desempeño más bajo, con errores de 21.56% y 22.36%. En conjunto, estos resultados se vieron relacionados con la complejidad que tiene el Bitcoin, marcada por su alta volatilidad que tiene y la ausencia de una estacionalidad clara ya que suele subir y bajar sin seguir un patrón, esto supera las capacidades de los modelos lineales de descomposición simple.


El comportamiento de cada modelo se vio influenciado directamente con su arquitectura y su forma de procesar la serie de tiempo del Bitcoin, la cual presenta una fuerte tendencia alcista, pero interrumpida por episodios de ruidos que se encuentran muy marcados. El modelo ARIMA falló al intentar estabilizar la serie mediante la diferenciación, ya que después de identificar una subida inicial, su proyección se volvió totalmente plana, perdiendo la capacidad de reaccionar ante los cambios bruscos conservados en los últimos 50 días. Prophet logró captar la tendencia general del crecimiento a largo plazo, pero mostró un sesgo optimista que lo llevó a proyectar un precio alto de 88,414.37 USD, sin reflejar la caída real hacia los 71,200.00 USD. En el caso de los modelos de Deep Learning, la LSTM logró ajustarse bastante bien a los movimientos que tuvo el mercado gracias a que este modelo da mayor peso a lo reciente, el Transformer por lo contrario, presentó un suavizado excesivo, al intentar reducir el ruido para encontrar la estabilidad, por la cual terminó perdiendo parte de la señal de crecimiento, lo que tuvo como consecuencia que su predicción se mantuviera por debajo del precio real. Finalmente, el modelo de IAG no se limitó a seguir la inercia que tenía los datos, sino que identificó señales más estructurales de agotamiento en la tendencia bajista de corto plazo permite anticipar un rebote técnico con una precisión que destaca ya que ningún otro modelo alcanzó.

La interpretabilidad de los modelos es igual de importante que precisión, ARIMA y Prophet son modelos que suelen considerarse más transparentes porque sus componentes; tendencia, estacionalidad y ruido se pueden analizar de forma directa desde su formulación matemática. Por otro lado, LSTM y Transformer funcionan como “cajas negras”, aunque estos modelos son

eficaces para procesar datos escalados entre 0 y 1, no permiten entender con facilidad el razonamiento que existe detrás de una predicción. La explicabilidad en el caso de Gemini, se llevó a cabo mediante un prompting estructurado, que justificó su predicción de 71,300.00 USD en relación con la varianza de los datos y la relevancia de la información más reciente. El modelo explicó que aunque al inicio se observó una alta volatilidad con un pico seguido de caída, posteriormente identificó una fase de consolidación.

Tras evaluar tanto la precisión como la explicabilidad, el modelo Gemini se puede considerar el más solo para esta serie de tiempos. Aunque la LSTM generó una apreciación cercana (72,455.61 USD), el modelo de IAG no solo logró ser más preciso, sino que también explicó el comportamiento esperado del precio ante una menor presión de venta. Además, su capacidad de realizar zero-shot forecasting sin entrenamiento específico le da ventaja frente a la LSTM, que requiere un proceso de entrenamiento más exigente.

Comparativa Final de Precisión: BITCOIN



EVALUACIÓN DE DESEMPEÑO Y COMPARATIVA DE MÉTRICAS DE ERROR (BITCOIN)				
VALOR REAL DE REFERENCIA: \$71,200.00 USD				
Modelo	MAE (USD)	RMSE	MAPE (%)	sMAPE (%)
IAG Gemini	\$100.00	100.00	0.1404%	0.1404%
LSTM	\$1,255.61	1,255.61	1.7635%	1.7481%
Transformer	\$9,691.05	9,691.05	13.6110%	14.6050%
Prophet	\$17,214.37	17,214.37	24.1775%	21.5699%
ARIMA	\$17,924.27	17,924.27	25.1745%	22.3600%
Nota: El ranking está ordenado por sMAPE (precisión simétrica).				


VIX – Volatility Index

Después de evaluar el desempeño de los modelos utilizados para predecir el comportamiento del índice de VIX, se puede observar diferencias claras en la precisión de cada enfoque, a partir de los métricas de error porcentual; el modelo de IAG fue el que obtuvo los mejores resultados, con el MAPE más bajo de 2.51% y un sMAPE de 2.54%. En el segundo se encuentra la red neuronal LSTM, que también mostró una buena capacidad para capturar la dinámica de la serie, por otro lado, los modelos estadísticos tradicionales tuvieron un desempeño más limitado en este caso. ARIMA alcanzó un sMAPE de 15.43%, mientras que Prophet presentó el error más alto del análisis, con un MAPE de 36.01% y un sMAPE de 30.52%. El modelo Transformer, aunque es más reciente que LSTM se ubicó en un punto intermedio con un sMAPE de 7.74%, lo cual indica que para este tipo de series los enfoques recurrentes o el análisis generativo resultaron ser más precisos.

El comportamiento de los modelos se encuentra relacionados directamente con su naturaleza técnica y la volatilidad del VIX. En el caso de los modelos estadísticos como ARIMA estos tendieron a estabilizarse rápidamente en una línea alrededor de los 16.73 puntos, lo que hizo que perdiera su capacidad para reflejar las caídas bruscas o cambios repentinos en el sentimiento del mercado. Por su parte, Prophet terminó sobreestimando la volatilidad el final del periodo, proyectando 19.49 puntos frente a los 14.33 reales. Los modelos de Deep Learning como la LSTM mostraron una mejor adaptación a la fase de relajación del VIX después de un pico, ajustándose con una mayor precisión al proceso de reversión a la media. El Transformer presentó un comportamiento más estable y conservador, lo que le permitió identificar el nivel de base de incertidumbre. Y por último, la IAG Gemini destacó por su capacidad de razonamiento zero-shot, logrando una predicción de 13.97 puntos, la cual es la más cercana al valor real de 14.33, al identificar patrones de estabilización que otros modelos no lograron captar.

La explicabilidad (XAI) se centró en el modelo IAG Gemini que no solo generó una predicción, sino que también explicó su resultado a partir del análisis de tendencias y la importancia de los datos más recientes. Por ejemplo, el modelo identificó una ligera recuperación después de un mínimo cercano a 13.47, dando mayor peso a los eventos recientes para reducir la incertidumbre. Aunque este análisis no se aplicaron otras técnicas, es posible que considerar en los próximos avances herramientas como mecanismos de atención, análisis de importancia temporal o métodos como SHAP para entender mejor el funcionamiento de estos modelos.

Tomando en cuenta tanto la precisión como la capacidad de interpretación, el modelo Gemini se posiciona como el más completo en este estudio, no solo representó la menor diferencia respecto al valor real, con apenas de 0.36 puntos, sino además aporta un análisis cualitativo que los otros modelos no ofrecen.



EVALUACIÓN DE DESEMPEÑO Y COMPARATIVA DE MÉTRICAS DE ERROR (VIX - VOLATILITY Index)				
VALOR REAL DE REFERENCIA: \$14.33 USD				
Modelo	MAE (USD)	RMSE	MAPE (%)	sMAPE (%)
IAG Gemini	\$0.36	0.36	2.5122%	2.5442%
LSTM	\$0.60	0.60	4.1970%	4.2870%
Transformer	\$1.15	1.15	8.0517%	7.7401%
ARIMA	\$2.40	2.40	16.7268%	15.4358%
Prophet	\$5.16	5.16	36.0179%	30.5214%

Nota: El ranking está ordenado por sMAPE (precisión simétrica).

Desempeño educativo

World Bank Education Statistics Kaggle

Este dataset contiene diversidad de datos, pero lo que nos interesa es acerca de la Tasa Bruta de inscripciones escolar a nivel primaria en donde se mide la cantidad de estudiantes inscritos a nivel primaria en todo el mundo, para posteriormente predecir la evolución de esta cifra al 2016. Nuevamente nuestras métricas iniciando con Prophet con un error de 1.56%, en cambio en Arima nos dio un rendimiento superior con un 0.29% en MAPE con un R^2 elevado de 0.70% mostrando que la educación ha tenido un crecimiento constante, con LSTM con un MAPE de 1.25% además de capturar la persistencia de los cambios generacionales y Transformer con un MAPE de 4.56% con un mecanismo de atención mostrando los cambios ocurridos durante 15 años con un peso mayor hacia la predicción del 2026 y Media Movil siendo de los modelos más precisos con un MAPE de 0.57% dándonos una limpieza eficaz de los datos.

El modelo con menor error fue Media móvil y de mayor fue Prophet. Con base a XAI podemos ver que ARIMA y Prophet son los más transparentes dado que nos muestran la tendencia lineales en cambio LSTM y Transformer son los que más presentan “Caja Negra” porque no se sabe el punto exacto de la decisión nos dio la precisión exacta. Incluso podemos ver que LSTM demostró el 49% de la predicción depende del último tercer año lo que nos indica que los resultados que nos dio la proyección dependen de las políticas de los últimos tres años, y en cuanto a Gemini podemos analizar que valida la lógica humana con y los datos cuantitativos. En cambio ARIMA fue el mejor modelo con una precisión técnica y estable con el MAE más bajo de 0.29 dado que sus cambios son lineales. La IA ha demostrado que muchos de los estudiantes vuelven a la escuela después de cierto tiempo.

Times World University Rankings Dataset Kaggle

Este dataset trata acerca de averiguar el ranking o la universidad más top del momento y que variable es la causante de dicho éxito, por lo que también se hará una predicción hasta el 2026. Se va iniciar analizando nuestras métricas con el mejor desempeño que en este caso fue LSTM con un MAPE de 0.42% y con un R^2 con un 0.97 dándonos como resultado una excelente memoria capturada. Arima por el otro lado fue la que más enfrentó dificultades con un MAPE de 3.86% y Prophet con un MAPE de 4.87% debido a que tuvieron los errores más altos de todos los modelos, y esto se debió a que los datos no son lineales, por lo que los modelos de Deep Learning como TRANSFORMER con un rendimiento más o menos con un MAPE de 3.09% sin embargo aún Media Móvil pudo lograr una estabilidad con un MAPE de 2.40%.

Nuevamente y con base a XAI podemos ver que ARIMA y Prophet son los más transparentes dado que nos muestran la tendencia lineales pero no lograron ser tan eficaces en cambio LSTM y Transformer son los que más presentan “Caja Negra” pero si se logra verificar que el año t-3 fue el de mayor importancia en la predicción dándonos a entender que el éxito de las universidades fueron gracias al esfuerzo de años pasado (3 en este caso) que Gemini pudo comprobar humanizando los datos . En cambio LSTM fue el mejor modelo con una precisión técnica y profunda con el MAE más bajo de 0.24 siendo el adecuado en un contexto de datos crecientes . En el 2026 se predijo que la excelencia escolar será alta.

UNESCO – Tasa de Finalización (Secundaria básica, ambos sexos)

Tras completar la parte tanto de experimentación como evaluación de los distintos modelos utilizados para proyectar la tasa de finalización de la educación secundaria en México, se llevó a cabo una comparación entre los modelos en relación a su desempeño. Al analizar las métricas de error, se observó que el modelos de ARIMA fue el más preciso, ya que fue el más preciso y obtuvo valores más bajos en esta comparación, con MAPE de 0.0240% y un sMAPE de 0.0240%. En el otro extremo se encuentra Transformer quien presentó el desempeño más bajo, alejándose de una forma considerada del valor real con un sMAPE de 3.7350%. El modelo de IAG (Gemini) y los modelos de Deep Learning (LSTM) se ubicaron en un nivel intermedio con una buena precisión, registrando un sMAPE de 0.2302% y 0.3508%, mientras que Prophet mostró un error ligeramente mayor de 0.6070%.

El comportamiento de cada uno de los modelos se encuentra relacionado directamente con la naturaleza de la serie temporal que fue analizada, la cual presenta una tendencia ascendente, constante y marcada. En este caso, el buen rendimiento de ARIMA se explica porque mediante la diferenciación, esta se logró estabilizar la serie y capturar con bastante precisión el crecimiento progresivo del sistema educativo mexicano. El modelo LSTM demostró que tiene una buena capacidad para comprender la relación secuencial que existen entre los datos, lo cual indica que el progreso educativo tiene una inercia de crecimiento estable. Por otro lado, Transformer tomó un comportamiento más conservador y la IAG obtuvo resultados sobresalientes mediante el enfoque zero-shot forecasting identificado la inercia reciente sin la necesidad de un entrenamiento previo.

La explicabilidad (XIA) está centrado en el modelo de IAG Gemini, este no solo proporcionó una número de predicción sino que también fue capaz de justificar el porqué de sus resultados a partir de los patrones que identificó, como el crecimiento que se tenía y la inercia del sistema.

Para seleccionar el mejor modelo en esta serie de tiempo, se consideró tanto la predicción como también la capacidad de ajustarse a la realidad de los datos, ARIMA fue el que se posicionó como el más destacado en términos de exactitud en la precisión, con una diferencia muy mínima de 0.02 puntos porcentuales. Por otro lado, si se busca una balance entre precisión y comprensión del texto, el modelo IAG también resulta muy valioso ya que quedó a solo 0.21 puntos del valor objetivo y además también aporta explicación coherente sobre sus resultados.



EVALUACIÓN DE DESEMPEÑO Y COMPARATIVA DE MÉTRICAS DE ERROR: TASA DE FINALIZACIÓN SECUNDARIA (MÉXICO))				
VALOR REAL DE REFERENCIA (UNESCO): \$90.88%				
Modelo	MAE (Puntos)	RMSE	MAPE (%)	sMAPE (%)
ARIMA	0.02	0.02	0.0240%	0.0240%
IAG Gemini	0.21	0.21	0.2304%	0.2302%
LSTM	0.32	0.32	0.3502%	0.3508%
Prophet	0.55	0.55	0.6089%	0.6070%
Transformer	3.33	3.33	3.6665%	3.7350%

Nota: El ranking está ordenado por sMAPE (precisión simétrica).

Conclusión

Después de analizar los tres sectores se puede observar que no existe un modelo único que sea mejor en todos los casos, ya que su desempeño depende directamente de la naturaleza de las características de la serie de tiempo. En el ámbito de salud pública, ARIMA destacó en series con tendencias estables y lineales, como en el caso de “La esperanza de vida y fertilidad”, lo cual se debe a su consistencias frente a modelos como Prophet que tendió a sobre ajustarse. Sin embargo, cuando se trabajó con datos que son más volátiles como la “Calidad del aire”, LSTM mostró mejores resultados al lograr capturar los cambios bruscos y factores ambientales que los modelos más simples no lograron considerar.

En el sector financiero, que se encuentra más caracterizado por alta volatilidad y ruido, la IAG (Gemini) fue la que tuvo un mejor desempeño, mientras que los modelos estadísticos se volvieron demasiados lineales y el modelo Transformer suavizó en exceso la tendencia, perdiendo así la señales importantes de crecimiento, en el cual la IAG logró identificar tanto patrones estructurales como cambios recientes con mayor precisión.

Y por último, en el caso del desempeño educativo, ARIMA se volvió a posicionar como el modelo más efectivo para captar el crecimiento constante y progresivo en la educación básica. En los datos más complejos y que no son lineales, como los rankings universitarios, logró sobresalir la memoria del LSTM que permitió ajustarse mucho más cercano a la realidad en comparación de los modelos tradicionales.

En conclusión, se podría decir que cuando los datos son estables, los modelos clásicos suelen funcionar mejor pero en contextos más volátiles, el uso de aprendizaje profundo e inteligencia artificial resulta más adecuado.